

Filtro de Kalman

Sistemas Lineares

Jeferson Lima

<http://gitlab.com/jeferson.lima>

3 de março de 2020

Informações Úteis

Material disponível em:

<https://gitlab.com/cursoseaulas/robotica-movel/-/wikis/home>

Informações Úteis

Material disponível em:

<https://gitlab.com/cursoseaulas/robotica-movel/-/wikis/home>

Datas Importantes

- ▶ Entrega
- ▶ Envio

Informações Úteis

Material disponível em:

<https://gitlab.com/cursoseaulas/robotica-movel/-/wikis/home>

Datas Importantes

- ▶ Entrega
- ▶ Envio

Requisitos da Disciplina

- ▶ Teoria de Controle
- ▶ Linguagem de Programação - **Python** ou **C++**
- ▶ Eletrônica

Teorema de Bayes

Revisão

Revisão

- ▶ Estado Estimado x de um sistema observado z e com controle em u .
- ▶ Objetivo:

$$P(x|z, u) \tag{1}$$

Bayes Filter

Revisão

$$\text{Bel}(x_t) = \eta P(z_t|x_t) \int P(x_t|u_t, x_{t-1}) \text{Bel}(x_{t-1}) dx_{t-1}$$

► Predição:

$$\overline{\text{Bel}}(x_t) = \int P(x_t|u_t, x_{t-1}) \text{Bel}(x_{t-1}) dx_{t-1}$$

► Correção:


$$\text{Bel}(x_t) = \eta P(z_t|x_t) \int P(x_t|u_t, x_t) \overline{\text{Bel}}(x_t) dx_{t-1}$$

Distribuição Normal (Gaussiana)

Revisão

► Uma Variável: $P(x) \sim N(\mu, \sigma^2)$


$$P(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$$



Distribuição Normal (Gaussiana)

Revisão

- Bivariável: $P(\mathbf{x}) \sim N(\mu, \Sigma)$



Distribuição Normal (Gaussiana)

Revisão

- Bivariável: $p(\mathbf{x}) \sim N(\mu, \Sigma)$

$$P(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{d}{2}} \|\Sigma\|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\}$$

- Para um sistema de duas Variável:

$$p(\mathbf{x}) \sim N(\mu, \Sigma)$$

logo:

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \right)$$

Distribuição Normal (Gaussiana)

Propriedades

► Caso Univariável:

$$\left. \begin{array}{l} X \sim N(\mu, \sigma^2) \\ Y = aX + b \end{array} \right\} \Rightarrow Y \sim N(a\mu + b, a^2\sigma^2) \quad (2)$$

► Caso Multivariável:

$$\left. \begin{array}{l} X \sim N(\mu, \Sigma) \\ Y = AX + B \end{array} \right\} \Rightarrow Y \sim N(A\mu + B, A\Sigma A^T) \quad (3)$$

Kalman filter

Modelo determinístico e estocástico

- ▶ Num **modelo determinístico** o resultado do sistema é pré determinado em função dos dados de entrada, exemplo:

$$x_t = A_t x_{t-1} + B_t u_t$$

$$z_t = C_t x_t$$

- ▶ Num **modelo estocástico** o resultado do sistema não depende somente dos dados de entrada, mas também de outros fatores, normalmente aleatórios:


$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t \quad (4)$$

$$z_t = C_t x_t + \delta_t \quad (5)$$

- ▶ A_t Matriz $(n \times n)$ que descreve os estados do modelo.
- ▶ B_t Matriz $(n \times l)$ que descreve os estados do controle.
- ▶ C_t Matrix $(k \times n)$ sendo os estados de x_t .
- ▶ ε_t Variável aleatória do processo.
- ▶ δ_t Ruído aleatório com distribuição normal e covariância de R_t e Q_t .



Kalman filter

Representação Grafica






Kalman filter

Representação Grafica






Kalman filter

Representação Grafica



Kalman filter




Representação Grafica



Como encontrar a solução para o grafico azul?

Kalman filter

Representação Grafica



Como encontrar a solução para o grafico azul?

$$p(x_t|z_t, u_t) = \eta p(z_t|x_t) p(x_t|z_{t-1}, u_t)$$

onde:

z_t : estado observado no tempo t

u_t : ação no tempo t

x_t : estado do sistema em t

Kalman filter

Revisão

$$\text{Bel}(x_t) = P(x_t|u_1, z_1, \dots, z_t)$$

$$\text{Bayes} = \eta P(z_t|x_t, u_1, z_1, \dots, u_t) P(x_t, u_1, z_1, \dots, u_t)$$

$$\text{Markov} = \eta P(z_t|x_t) P(x_t, u_1, z_1, \dots, u_t)$$

$$\text{Prob. Total} = \eta P(z_t|x_t) \int P(x_t|u_1, z_1, \dots, u_t, x_{t-1})$$

$$P(x_{t-1}|u_1, z_1, \dots, u_t) dx_{t-1}$$

$$\text{Markov} = \eta P(z_t|x_t) \int P(x_t|u_t, x_{t-1}) P(x_{t-1}|u_1, z_1, \dots, u_t) dx_{t-1}$$

$$\text{Markov} = \eta P(z_t|x_t) \int P(x_t|u_t, x_{t-1}) P(x_{t-1}|u_1, z_1, \dots, z_{t-1}) dx_{t-1}$$

Bayes Filter

$$\text{Bel}(x_t) = \eta P(z_t|x_t) \int P(x_t|u_t, x_{t-1}) \text{Bel}(x_{t-1}) dx_{t-1}$$

Kalman filter

Algoritmo

- ▶ Iniciando as Variável:

$$\text{Bel}(x_0) = N(x_0, \mu_o, \Sigma_0) \quad (6)$$

- ▶ Tempo de convergência do filtro.

Kalman filter

Algoritmo

- ▶ Com base na equação:

$$\text{Bel}(x_t) = \eta P(z_t|x_t) \int P(x_t|u_t, x_{t-1}) \text{Bel}(x_{t-1}) dx_{t-1}$$

- ▶ E considerando que o sistema abaixo é linear e observável:

$$x_t = A_t x_{t-1} + B_t u_t$$

$$z_t = C_t x_t$$

- ▶ Um sistema é observável se o posto da matriz \mathcal{O} é igual a n .

$$\mathcal{O} = \begin{bmatrix} C_t \\ C_t A_t \\ C_t A_t^2 \\ \vdots \\ C_t A_t^{n-1} \end{bmatrix}, \quad \text{rank}(\mathcal{O}) = n$$

Kalman filter

Algoritmo - Prediction

- Temos a função de probabilidade do sistema, expressa por:

$$p(x_t|u_t, x_{t-1}) = N(x_t; A_t x_{t-1} + B_t u_t, Q_t)$$

- ou seja:

$$\overline{\text{Bel}}(x_t) = \int \underbrace{P(x_t|u_t, x_{t-1})}_{\sim N(x_t; A_t x_{t-1} + B_t u_t, Q_t)} \underbrace{\overline{\text{Bel}}(x_{t-1})}_{\sim N(x_{t-1}; \mu_{t-1}, \sum_{t-1})} dx_{t-1}$$

Kalman filter

Algoritmo - Prediction

$$\begin{array}{ccc} \overline{\text{Bel}}(x_t) & = \int P(x_t | u_t, x_{t-1}) & \text{Bel}(x_{t-1}) dx_{t-1} \\ & \Downarrow & \Downarrow \\ & \sim N(x_t; A_t x_{t-1} + B_t u_t, Q_t) & \sim N(x_{t-1}; \mu_{t-1}, \Sigma_{t-1}) \\ & \Downarrow & \end{array}$$

Relembrando ...

$$P(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{d}{2}} \|\Sigma\|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\}$$

$$\begin{aligned} \overline{\text{Bel}}(x_t) &= \eta \int \exp \left\{ -\frac{1}{2} (x_t - A_t x_{t-1} - B_t)^T Q_t (x_t - A_t x_{t-1} - B_t) \right\} \\ &\quad \exp \left\{ -\frac{1}{2} (x_{t-1} - \mu_{t-1})^T \Sigma_{t-1} (x_{t-1} - \mu_{t-1}) \right\} dx_{t-1} \end{aligned}$$

Kalman filter

Algoritmo - Prediction

► Continuando ...

$$\overline{\text{Bel}}(x_t) = \eta \int \exp \left\{ -\frac{1}{2} (x_t - A_t x_{t-1} - B_t)^T Q_t (x_t - A_t x_{t-1} - B_t) \right\} \\ \exp \left\{ -\frac{1}{2} (x_{t-1} - \mu_{t-1})^T \Sigma_{t-1} (x_{t-1} - \mu_{t-1}) \right\} dx_{t-1}$$

Prediction

$$\overline{\text{Bel}} = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases} \quad (7)$$

Kalman filter

Algoritmo - Measurement Update

- Considerando a saída do sistema:

$$z_t = C_t x_t + \delta_t$$

- Apresentadas as equações lineares do observador de estados, temos a função de probabilidade:

$$P(z_t | x_t) = N(z_t; C_t x_t, R_t)$$

- ou seja:

$$\text{Bel}(x_t) = \eta \underbrace{P(z_t | x_t)}_{\sim N(z_t; C_t x_t, Q_t^{-1})} \underbrace{\overline{\text{Bel}}(x_t)}_{\sim N(x_t; \bar{\mu}_t, \bar{\Sigma}_t)}$$

Kalman filter

Algoritmo - Measurement Update

$$\begin{array}{ccc} \text{Bel}(x_t) & = \eta & P(z_t|x_t) \quad \quad \quad \overline{\text{Bel}}(x_t) \\ & & \Downarrow \quad \quad \quad \Downarrow \\ & & \sim N(z_t; C_t x_t, Q_t) \quad \sim N(x_t; \bar{\mu}_t, \bar{\Sigma}_t) \\ & & \Downarrow \\ \text{Bel}(x_t) & = \eta & \exp \left\{ -\frac{1}{2} (z_t - C_t x_t)^T R_t (z_t - C_t x_t) \right\} \\ & & \exp \left\{ -\frac{1}{2} (x_t - \bar{\mu}_t)^T \bar{\Sigma}_t^{-1} (x_t - \mu_t) \right\} \end{array}$$

Measurement Update

$$\overline{\text{Bel}} = \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - C_t \bar{\mu}_t) \\ \Sigma_t = (I - K_t C_t) \bar{\Sigma}_t \end{cases} \quad (8)$$

$$\text{Com } K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + R_t)^{-1} \quad (9)$$

Kalman filter

Algoritmo

Algorithm 1 Kalman-filter

```
1: procedure PREDICTION( $\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$ )
2:    $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$ 
3:    $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t$ 
4:   Return ( $\bar{\mu}_t, \bar{\Sigma}_t$ )
5: end procedure
6: procedure MEASUREMENTUPDATE( $\bar{\mu}_t, \bar{\Sigma}_t, z_t$ )
7:    $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + R_t)^{-1}$ 
8:    $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$ 
9:    $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$ 
10:  Return ( $\mu_t, \Sigma_t$ )
11: end procedure
```

Kalman filter

Exercício

Kalman filter

Desafio Carro Autonomo x Ciclista

Referências